




# Introducción a la Ciencia de Datos

# Ciencia de Datos: Fundamentos y Herramientas


CD2023



# Deep Learning



Extraer patrones de los  
datos usando redes  
neuronales







- <https://this-person-does-not-exist.com/en>

# Recurrent Neural Networks

## Redes neuronales recurrentes

- Para procesar secuencias de datos  $x(t) = x(1), \dots, x(\tau)$
- Recurrente -> ejecuta la misma tarea para cada elemento de la secuencia, la salida depende de varias cuentas realizadas en muestras previas
- Tiene “memoria”




# Recurrent Neural Networks

RNNs como una manera de modelar problemas de secuencias de datos

Lo que necesitaría el modelo es:

- Manejar secuencias de **longitud variable**
- Trackear dependencias de **largo plazo (long-term)** dependences)
- Mantener la información sobre el **orden**
- **Compartir parámetros** a lo largo de la secuencia

Queremos pronosticar esto!




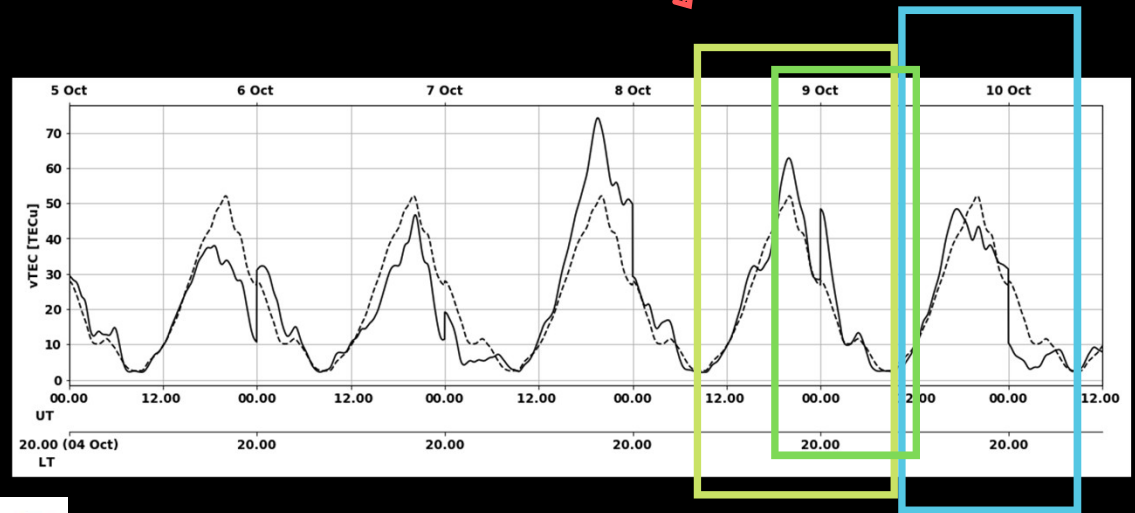


# Recurrent Neural Networks

RNNs as an approach to sequence modeling problems  
Lo que necesita el modelo es:

- Manejar secuencias de **longitud variable**
- Trackear dependencias de **largo plazo (long-term dependences)**
- Mantener la información sobre el **orden**
- **Compartir parámetros** a lo largo de la secuencia

Cuantos pasos? (longitud)




Y + arquitecturas

# Recurrent Neural Networks

RNNs as an approach to sequence modeling problems  
Lo que necesita el modelo es:

- Manejar secuencias de **longitud variable**
- Trackear dependencias de **largo plazo (long-term dependences)**
- Mantener la información sobre el **orden**
- **Compartir parametros** a lo largo de la secuencia

Que tan importante es la información del pasado (lejano)?




La serie podría tener comportamientos regulares (diarios, estacionales, etc.)

# Recurrent Neural Networks

RNNs as an approach to sequence modeling problems  
Lo que necesitamos el modelo es:

- Manejar secuencias de **longitud variable**
- Trackear dependencias de **largo plazo (long-term dependences)**
- Mantener la información sobre el **orden**
- **Compartir parametros** a lo largo de la secuencia




$vTEC(t-2), vTEC(t-1), vTEC(t-0) \leftrightarrow vTEC(t-0), vTEC(t-2), vTEC(t-1)$

# Recurrent Neural Networks

RNNs as an approach to sequence modeling problems  
Lo que necesitamos el modelo es:

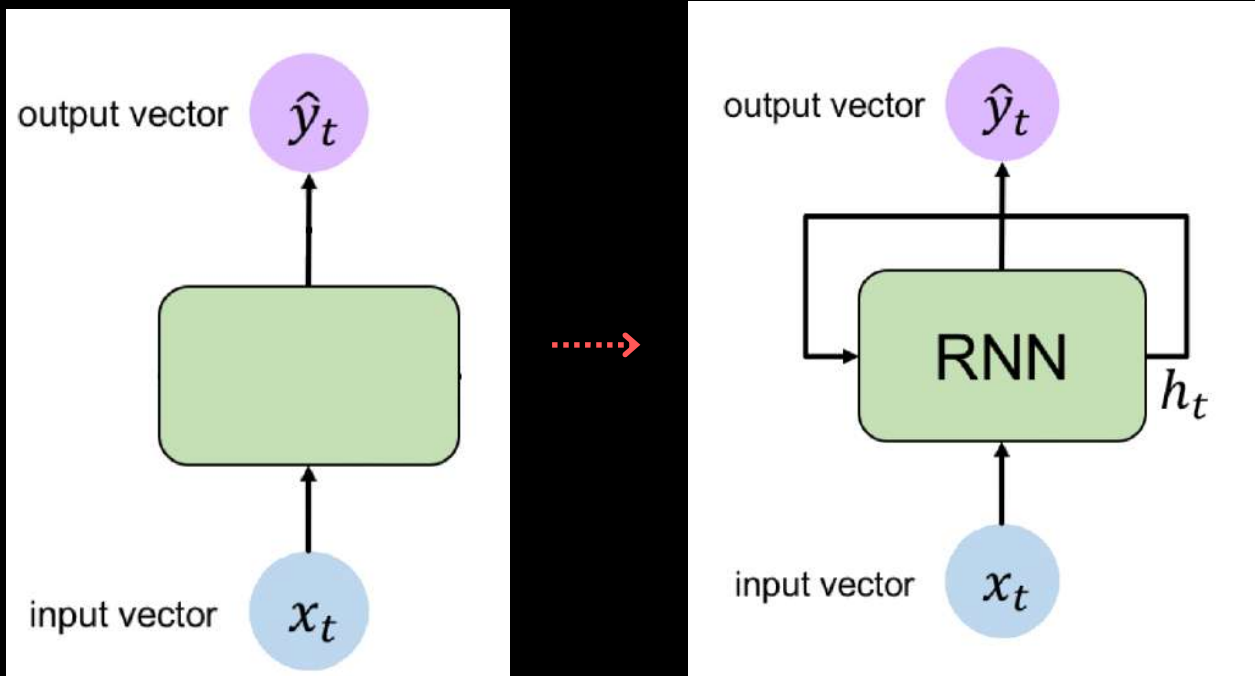
- Manejar secuencias de **longitud variable**
- Trackear dependencias de **largo plazo (long-term dependences)**
- Mantener la información sobre el **orden**
- **Compartir parametros** a lo largo de la secuencia



RNNs tienen un estado o **state** ( $h_t$ ), que es **actualizado en cada paso** a medida que la secuencia es procesada usando los **mismos parametros** en cada paso de tiempo



# Recurrent Neural Networks

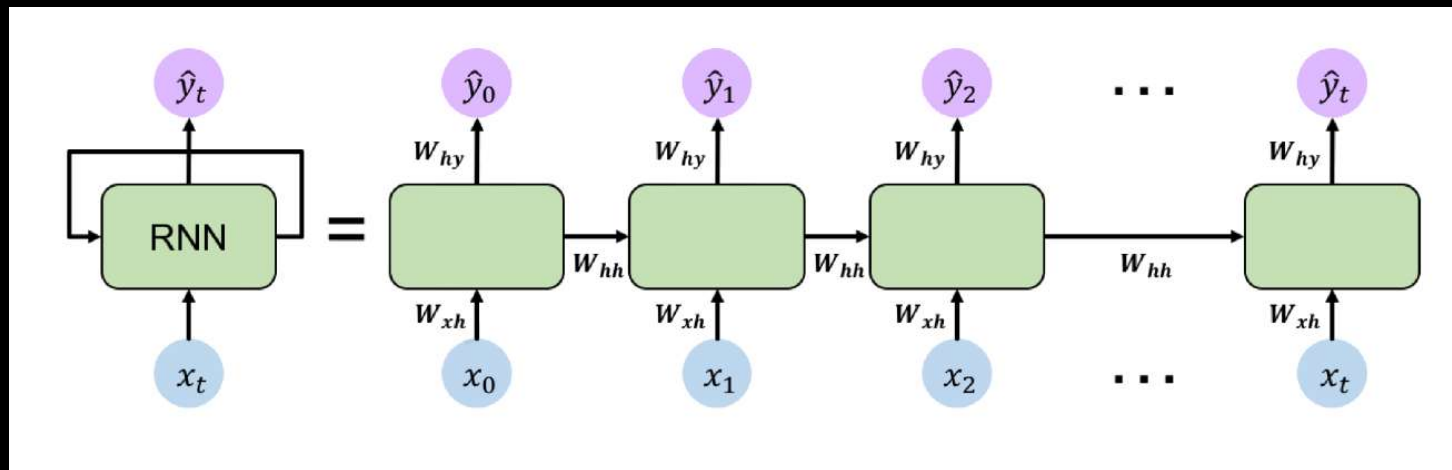


$$\boxed{h_t} = \boxed{f_W}(\boxed{h_{t-1}}, \boxed{x_t})$$


cell state      function parameterized by  $W$       old state      input vector at time step  $t$

- Aplica una **relacion recurrente** en cada paso de tiempo para procesar la secuencia

# Recurrent Neural Networks



# Backpropagation through time: long time dependences



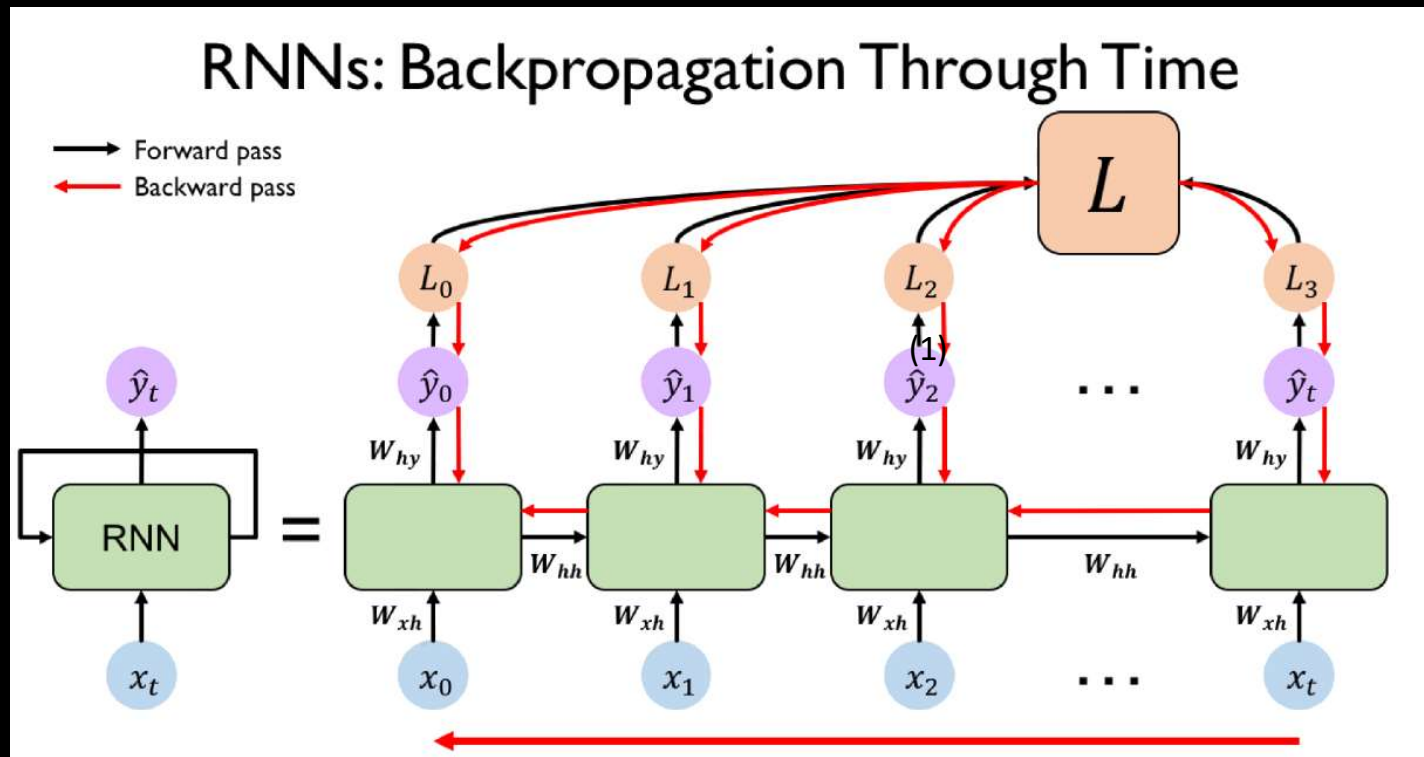
$$W^* = \operatorname{argmin}_W \frac{1}{n} \sum_{i=1}^n \mathcal{L}(f(x^{(i)}; W), y^{(i)})$$
$$W^* = \operatorname{argmin}_W J(W)$$

## Algorithm

1. Initialize weights randomly  $\sim \mathcal{N}(0, \sigma^2)$
2. Loop until convergence:
3. Compute gradient,  $\frac{\partial J(W)}{\partial W}$
4. Update weights,  $W \leftarrow W - \eta \frac{\partial J(W)}{\partial W}$
5. Return weights

- Toma el gradiente de la perdida (loss) con respecto a cada parametro
- Cambia parametros para poder minimizar la perdida


# Backpropagation through time: long time dependences



- Realiza la computacion individual de  $l_i$  para cada paso y los suma
- Hace backpropagation de los errores individuales de cada paso y luego de todos los pasos de tiempo hasta el inicio de la secuencia

<https://kharshit.github.io/blog/2019/02/22/backpropagation-through-time>

## Backpropagation through time: long time dependences



- Mucho tiempo de computo!

- Muchos valores  $\gg 1$   $\rightarrow$  exploding gradient (\*)
- Muchos valores  $\ll 1$   $\rightarrow$  vanishing gradient

(\*) Gradient clipping is a simple technique: If the gradient gets too large, we rescale it to keep it small.

# Vanishing gradient problem



Multiplica muchos numeros pequenos



Errores debido a que para aquellos pasos lejanos en el tiempo, los gradientes se hacen cada vez mas pequenos



Sesga los parametros y captura mayormente las dependencias de corto plazo

Como resolver el problema:

- Activation function
- Inicializacion de pesos
- Nuevas arquitecturas

# Vanishing gradient problem

Multiplica muchos numeros pequenos




Errores debido a que para aquellos pasos lejanos en el tiempo, los gradientes se hacen cada vez mas pequenos



Sesga los parametros y captura mayormente las dependencias de corto plazo

- Activation function



# Vanishing gradient problem

## Inicializacion de pesos

Multiplica muchos numeros pequenos



Errores debido a que para aquellos pasos lejanos en el tiempo, los gradientes se hacen cada vez mas pequenos



Sesga los parametros y captura mayormente las dependencias de corto plazo

$$I_n = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \end{pmatrix}$$

Inicializar **weights** con la matriz identidad  
Inicializar **biases** con cerp

Previene que los gradientes se vayan a cero



# Vanishing gradient problem

Multiplica muchos numeros pequenos




Errores debido a que para aquellos pasos lejanos en el tiempo, los gradientes se hacen cada vez mas pequenos



Sesga los parametros y captura mayormente las dependencias de corto plazo

- Nuecas arquitecturas

Solucion mas robusta




Usa unidades recurrentes con compuertas que son mas complejas para controlar el flujo de la informacion que se esta pasando a lo largo de la secuencia

Las compuertas agregan o remueven informacion selectivamente dentro de cada unidad recurrente

# Long short term memory (LSTM)

Gates: 1) Forget      2) Input (store)      3) Update      4) Output



Como trabaja:

1) Mantiene una celda de estado  
2) Usa compuertas (gates) para controlar el flujo de la información.

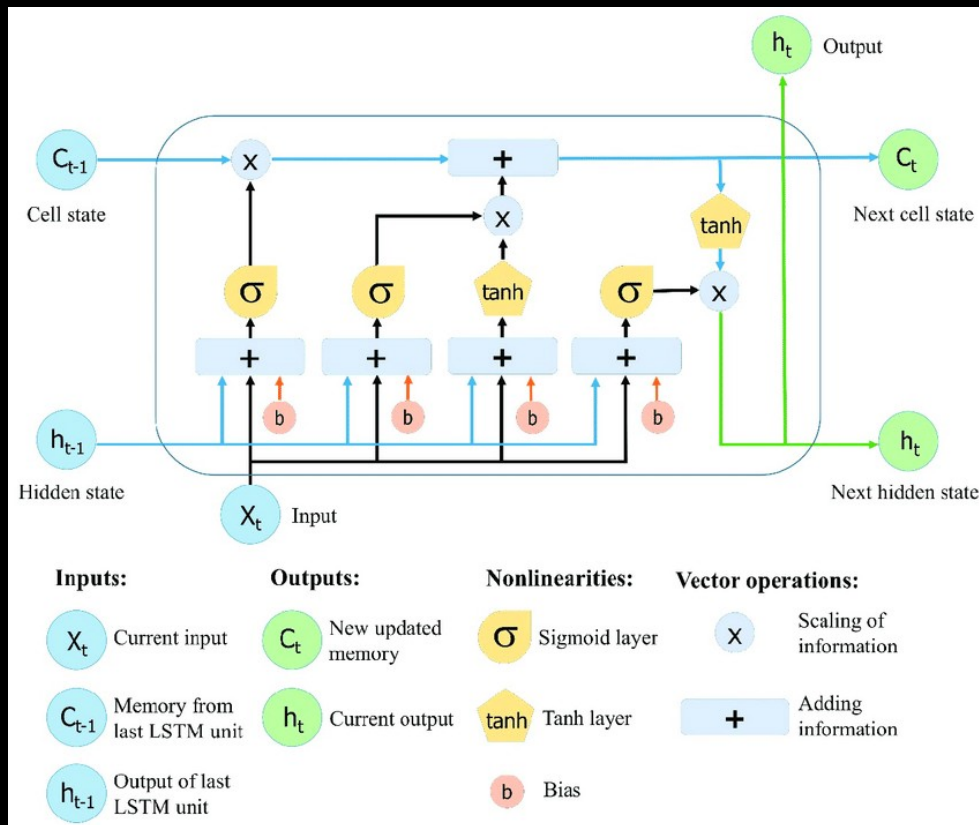
- Forget gate: se deshace de la información poco relevante
- Almacena información relevante de la entrada actual (store/input gate)
- Selectivamente hace un update de la celda de estado

Output gate: retorna la versión filtrada de la celda de estado

3) Backpropagation TT con flujo de gradientes parcialmente sin interrupciones

# Long short term memory (LSTM)

Gates: 1) Forget      2) Input (store)      3) Update      4) Output



How it works:

1) Maintain a **cell state**

2) Use gates to control the flow of information

- **Forget gate** gets rid of irrelevant information
- Store relevant information from the current input
- Selectively **update cell state**
- **Output gate** returns a filtered version of the cell state


3) Backpropagation TT with partially uninterrupted gradient flow

## LSTM "no todo lo que brilla es oro"

- << vanishing gradient problem .... pero no lo elimina completamente.
- >> Costo computacional
- Es afectado por diferentes inicializaciones aleatorias de los pesos
- Drop-out es difícil de implementar
- Tiende a hacer overfitting
- << performance en problemas con dependencias temporales muy largas

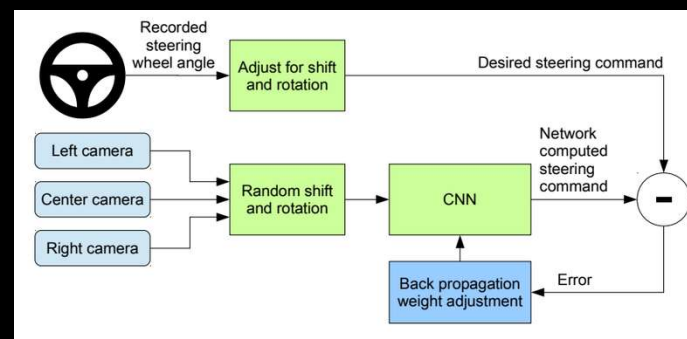



# Convolutional Neural Networks



**FIGURE 8.** Four sample images from our pig detection test set processed by the Faster R-CNN with the feature extraction layers pre-trained on ImageNet, the rest pre-trained on Pascal Visual Object Classes Challenge 2007 and an additional fully-connected layer for the pig dataset. Detections to the left of the red wall are ignored. The top left image is from the low-light test segment. The top right image is from the densely packed test-segment. The bottom left image is from the overexposed test segment. The bottom right image is from the many pigs test segment.

## CNNs



Computer Vision.

- Facial detection and recognition
- Healthcare, medicine and biology
- Self-driving vehicles



# Convolutional Neural Networks



157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	93	17	110	210	180	154
180	180	50	14	54	6	10	93	48	105	159	181
206	109	6	124	131	111	120	204	166	16	66	180
194	68	137	261	237	239	239	228	227	87	71	201
172	106	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	86	150	79	38	218	241
190	234	147	108	227	210	127	102	96	101	265	224
190	214	173	66	103	143	96	60	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	95	218

What the computer sees


157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	93	17	110	210	180	154
180	180	50	14	54	6	10	93	48	105	159	181
206	109	6	124	131	111	120	204	166	16	66	180
194	68	137	261	237	239	239	228	227	87	71	201
172	106	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	86	150	79	38	218	241
190	234	147	108	227	210	127	102	96	101	265	224
190	214	173	66	103	143	96	60	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	95	218

An image is just a matrix of numbers  $[0,255]$ !  
i.e.,  $1080 \times 1080 \times 3$  for an RGB image

# Features

(Como en otros problemas con NN)

- Regresion
- Classificacion
- Deteccion de features Ede alto nivel




Extraer las features a partir de los  
datos!

Aprender jerarquias de features!




# Fully conncteted NN



Input:

- 2D image
- vector de valores de pixeles  
(flatten the image)



Fully connected:

- Conectar una neurona de una capa oculta a todas las neuronas en la entrada
- No mantiene informacion espacial!
- Muchos parametros



Como le agregamos una estructura esacial a la entrada?



# Using spatial structure

Input:


- 2D image
- **Arreglo** de pixeles



Sliding window para definir las conecciones (conecta un parche en la capa de entrada a una sola neurona)

La clave: como podemos **pesar** cada parche para detectar una feature particular?

## Using spatial structure

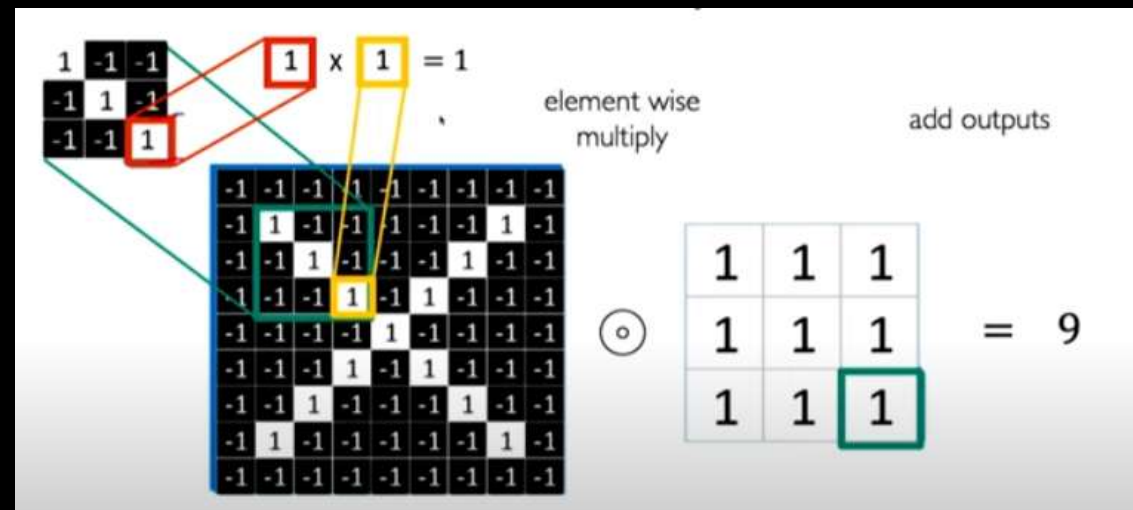




- Filtro de size 4x4: son 16 pesos diferentes
- Aplicar el mismo filtro a 4x4 parches en la entrada
- Mover 2 pixels para el proximo parche




Esta operacion se llama **convolucion**

- Aplicar un set de pesos ( un filtro) para extraer **features locales**
- Usar multiples filtros para extraer diferentes features
- Cada filtro **comparte espacialmente parametros**

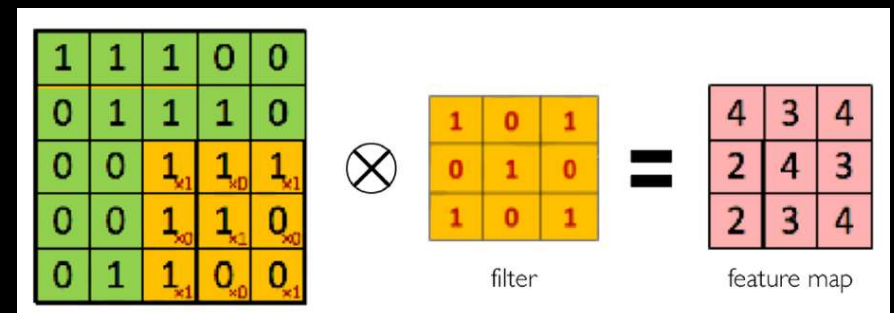
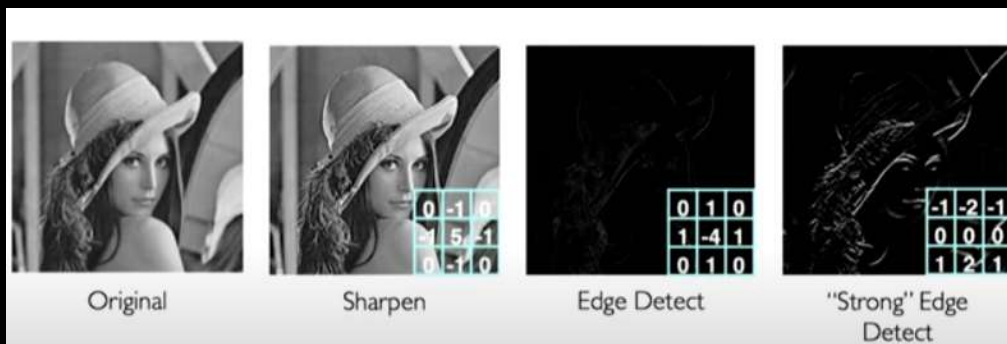
# Convolutional operation



# Convolutional operation

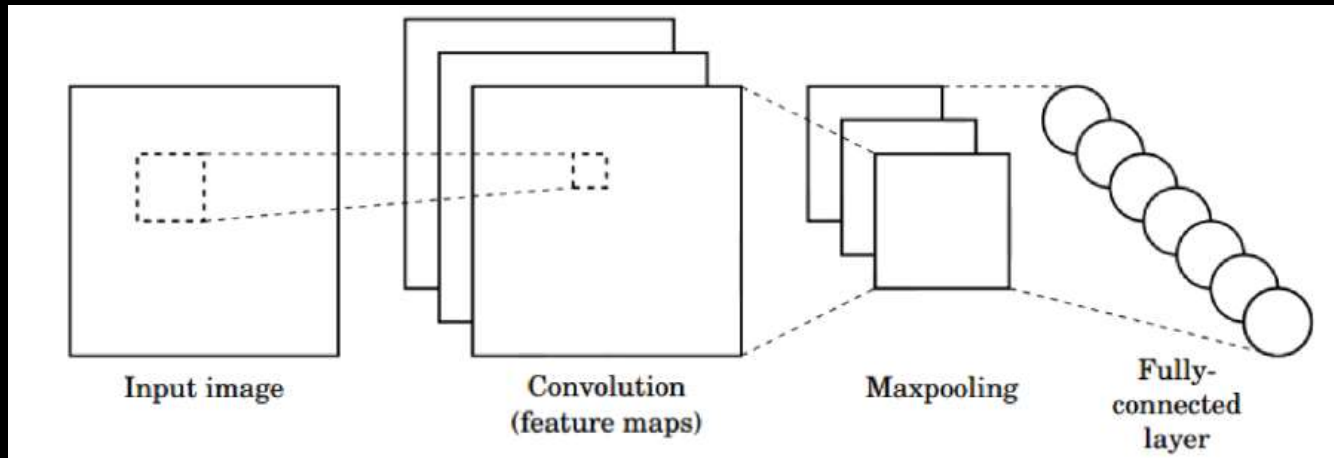


...



# Convolutional neural networks (CNN)




- for classification



- **Convolucion:** aplicar filtros para generar 'feature maps'
- **Non-linealidad:** mas usado ReLU
- **Pooling:** operacion de submuestreo (downsampling) en cada mapa de features

**Train model with image data.  
Learn weights of filters in convolutional layers.**

# Convolutional layer





1. Aplicar una ventana de pesos

2. calcular las combinaciones lineales

Para cada neurona de la capa oculta:

- Toma las entradas del parche
- Calcula la suma ponderada
- Aplica bias

3. se activa con una funcion no lineal



# Pooling

1	1	2	4
5	6	7	8
3	2	1	0
1	2	3	4

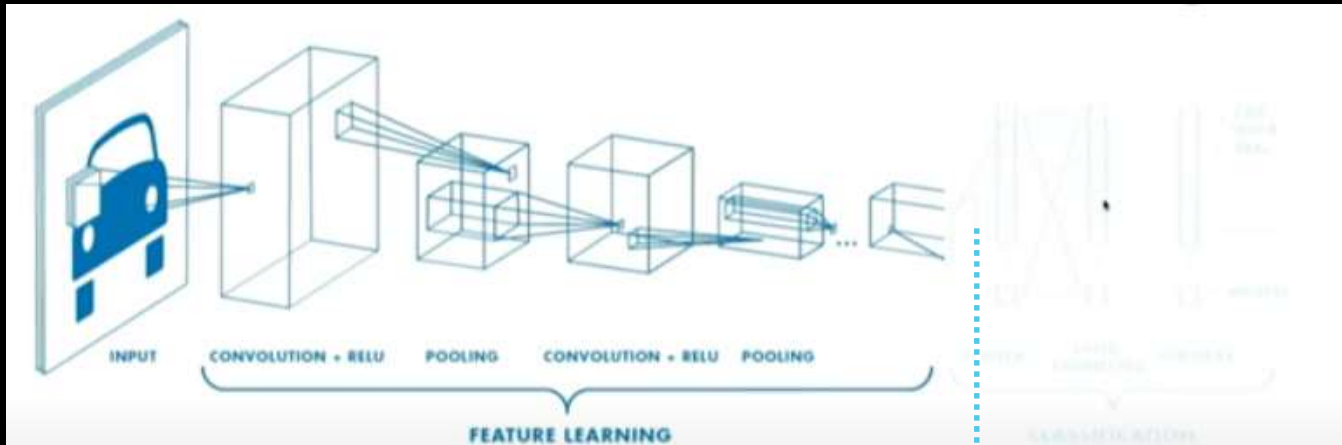
max pool con filtro 2x2  
Y un paso de 2



6	8
3	4

- Reduce la dimensionalidad
- Invarianza espacial

## CNN: classification example



- Hasta este punto, la ultima dalida e el i-esimo feature map



## CNN: classification example




CONV and POOL layers putput **high-level features** input


Salida de las capas CONV y POOL >> **features de alto nivel**

Una capa fully connected usa estas **features** para **clasificar** la image

Expresa la **salida como una probabilidad** (de la imagen a una cierta clase)



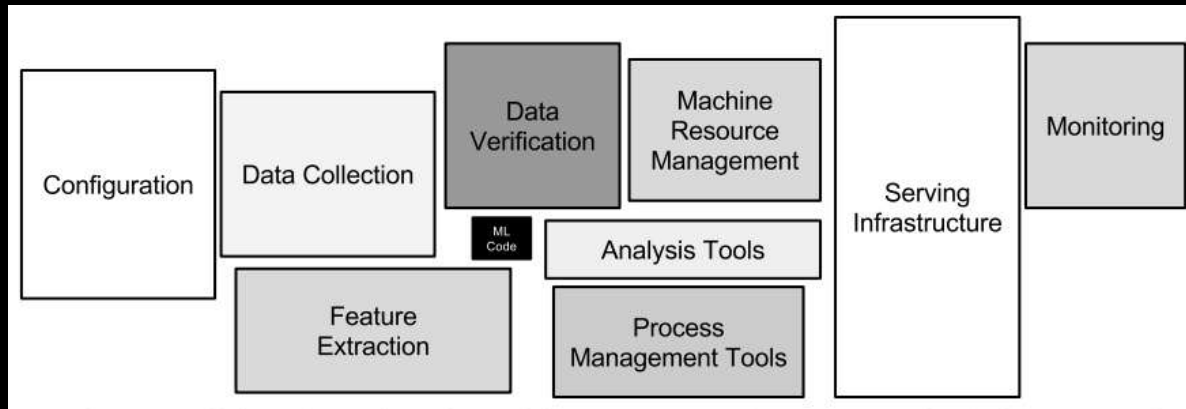
$$\text{softmax}(y_i) = \frac{e^{y_i}}{\sum_j e^{y_j}}$$



logits = predicciones no normalizados (aun del modelo)



# Deployment



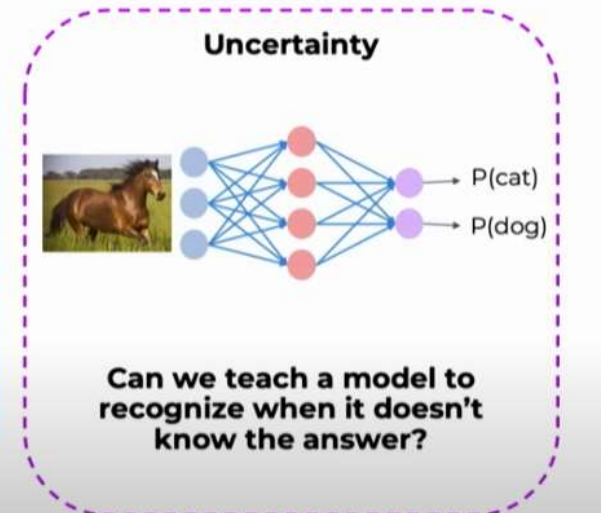
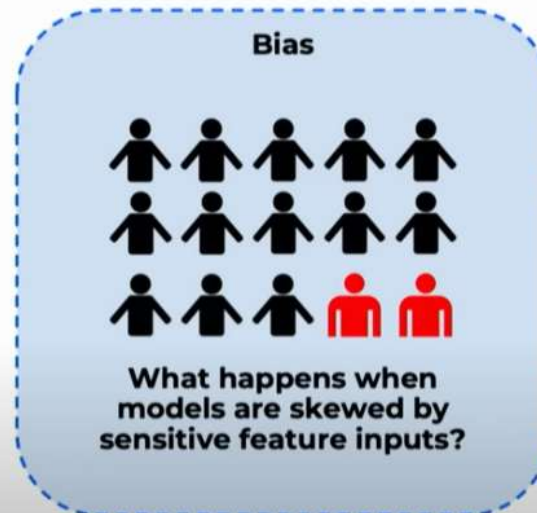
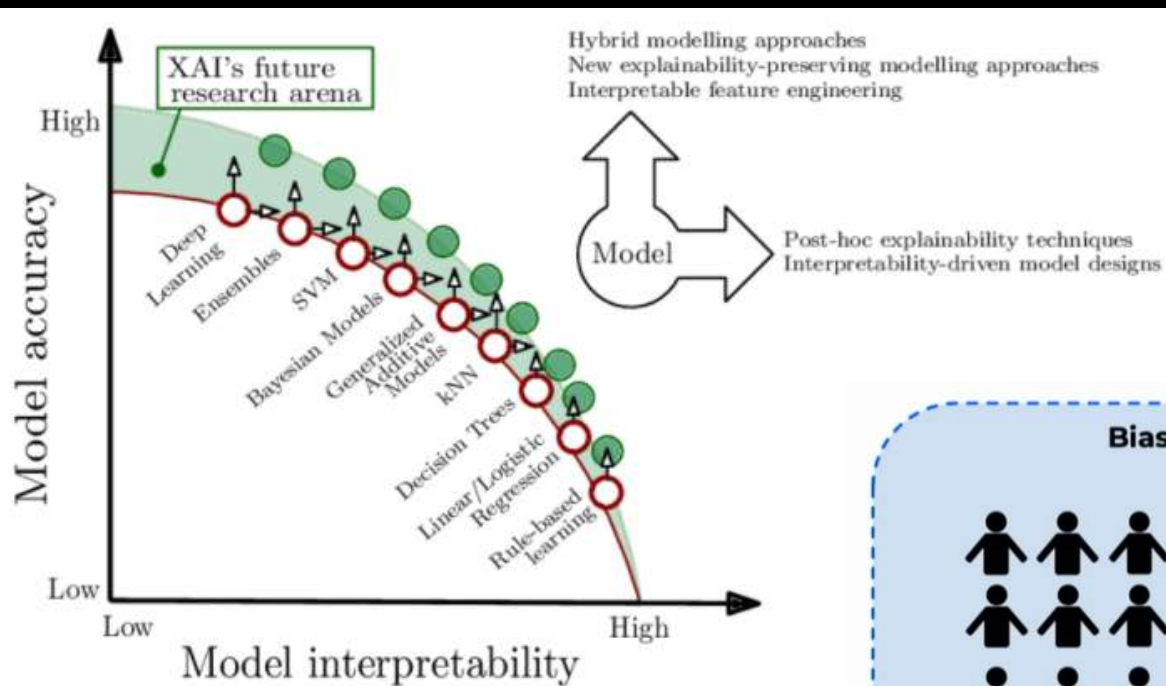
Hidden Technical Debt in Machine Learning Systems, D. Sculley et.al (2015)

- Tiene todos los problemas de deployment y manenimiento de un codigo tradicional mas los problemas especificos de ML
- El modelo es solo una pequena parte de un sistema operacional

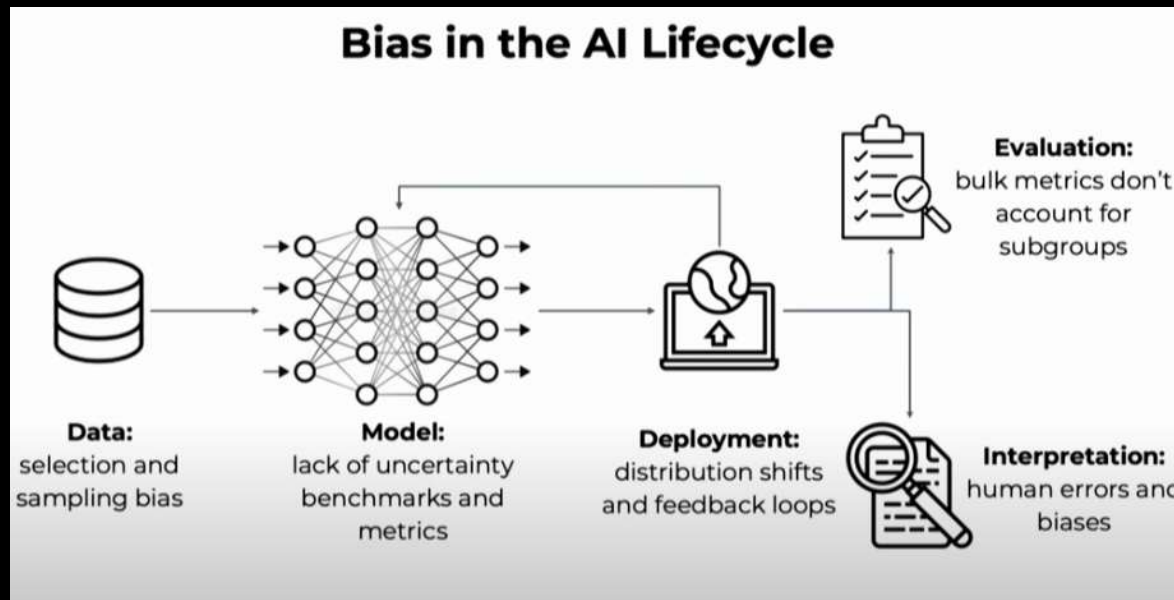
- How easily can an entirely new algorithmic approach be tested at full scale?
- What is the transitive closure of all data dependencies?
- How precisely can the impact of a new change to the system be measured?
- Does improving one model or signal degrade others?
- How quickly can new members of the team be brought up to speed?

# Robustness & Trusworthiness

Barredo +, 2019





# Robustness & Trusworthiness



# Robustness & Trusworthiness

## Mitigating Class Imbalance

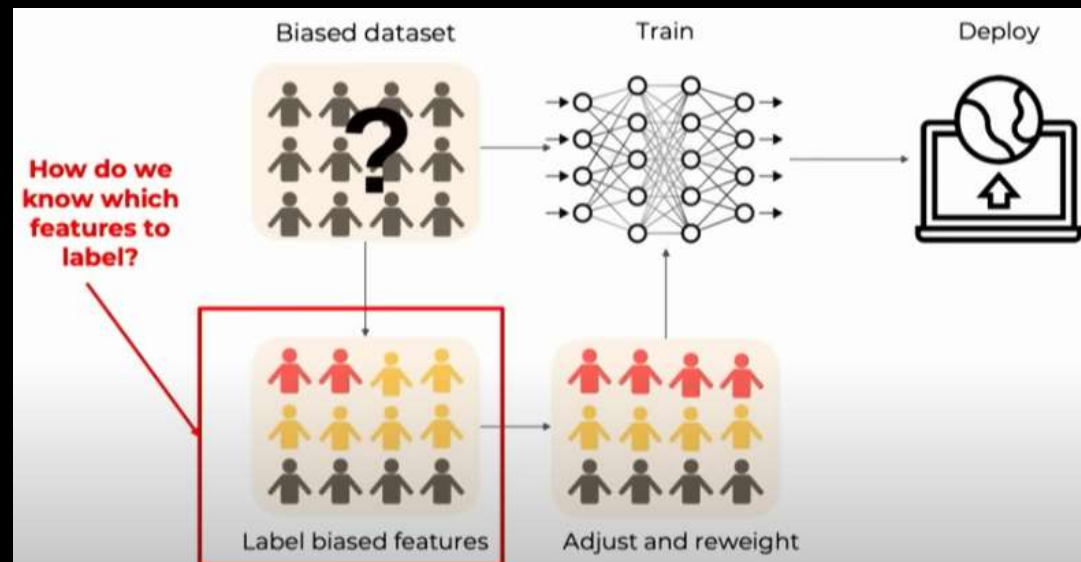
### Class Imbalance



- **Sample Reweighting:** Sample more data points from underrepresented classes
- **Loss Reweighting:** Mistakes on underrepresented classes contribute more to loss
- **Batch Selection:** Choose randomly from classes so that every batch has an equal number of points per class

# Robustness & Trustworthiness

Latent features






# Robustness & Trusworthiness

## Uncertainty



### Aleatoric vs. Epistemic Uncertainty



- **Aleatoric** uncertainty = data uncertainty
- Irreducible!
- Can be **directly** learned from data

- **Epistemic** uncertainty = model uncertainty
- Reducible by adding data!
- **Cannot** be directly learned from data

What if we train the same network multiple times (an **ensemble** of networks) and compare outputs?



```
num_ensembles = 5
for i in range(num_ensembles):
    model = create_model(...)
    model.fit(...)



raw_predictions = [models[i].predict(x)
                    for i in range(num_ensembles)]
mu = np.mean(raw_predictions)
uncertainty = np.var(raw_predictions)
```





## An application

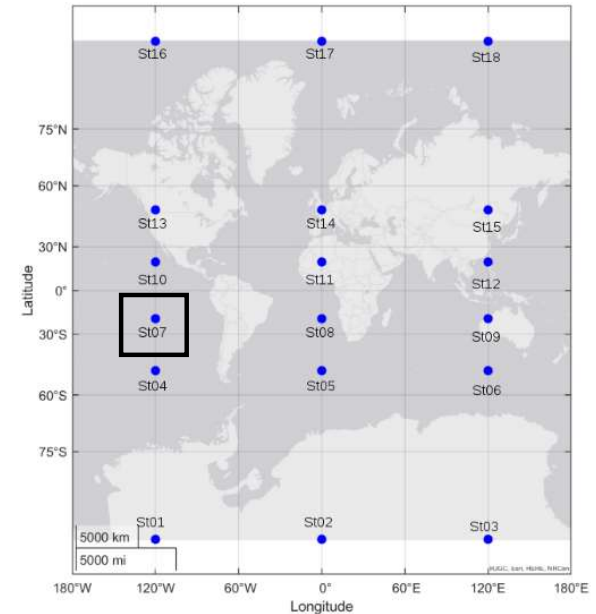
- 2 stages: **a) single station forecasting (ML);**  
b) extended forecasting
- 3 meridional sectors covering low, mid & high latitude
- Covering land & oceanic regions
- **Input: TEC from GIMs + External input (Kp)**



Molina +(submitted)

### Objectives:

- Global TEC forecast 24 hs ahead using DL
- Propose a semi-operative prototype




Cesaroni +, 2020



## An application

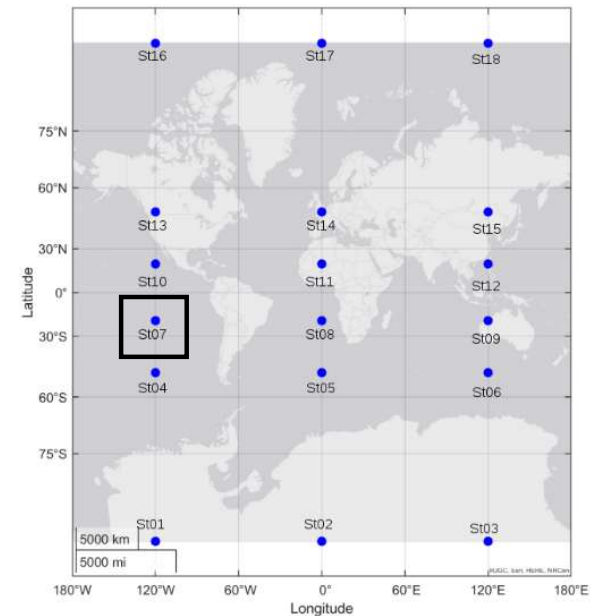
- 2 stages: **a) single station forecasting (ML);**  
b) extended forecasting
- 3 meridional sectors covering low, mid & high latitude
- Covering land & oceanic regions
- **Input: TEC from GIMs + External input (Kp)**



Molina + (under review)

### Objectives:

- Global TEC forecast 24 hs ahead using DL
- Propose a semi-operative prototype



Cesaroni +, 2020




## Data preparation & Feature selection


- Dataset:
  - 2005 - 2016
  - splitting strategy: 99% (99 train/1val) - 1% test (~43 days)
  - + cases study: geomagnetic storms in 2017
- Resolution (re-sampling):
  - TEC from GIMs - 2 hs resolution
  - Kp - 3hs resolution > K Nearest-neighbor interpolation
- Smart weight initialization (kernel initialization):  
GlorotNormal distribution + proper activation function (e.g. tanh).

Loosely physics-informed approach

St 01 TEC - dataset (2005 - 2016)




TEC - single ST Histogram






# ML modelling

- 3 ML techniques:
  - 2 RNNs (LSTM & GRU)
  - CNN (1D)
- Time series
- Hyperparameter tuning:  
grid search



- # hidden layers  
(5,10,15,20,50,100 cells)
- batch size (16,32,64,128)
- #epochs (iterations)  
(5,10,15,20,30,40,50,100,200,  
500,1000)




RNNs:

- Maintain order
- Memory ( $h_t$ )
- Backpropagation through time
- Prone to overfitting, vanishing gradient problem
- LSTM & GRU -> gated cells -> long-term but not that long

CNN:

- kernel size = 2








# ML modelling

- Forecasting 24 hs ahead (quiet day)
- RMSE < 3 TECu
- CNN best at any station (– St16,17,18 –> TECu<=1 –> quiet day)
- Low lat + oceanic stations –> + challenging

- Why these results?
  - LSTM & GRU -> difficult to catch fast changes and peaks
  - CNN (1D) -> spatial relationship = short term relationships







## ML modelling

- In general: in SWx, few extreme cases (unbalanced datasets) -> forecasting may fail when new data arrives (generalization is a problem)-> Incremental learning

RMSE



Test set -> 43 days with the basic models



Test set -> 43 days with the models + incremental learning (updating each 24 hs)



## ML modelling

- We considered cases study from 2017 under different geomagnetic conditions

$$Global \Delta TEC = \frac{1}{st} \sum^{st} \Delta TEC$$

